

Вывод формул.

Пусть S - размер батча, B - размер батча, Input: $B \times 3 \times S \times S$.

Conv.	Hout	Flops
$7 \times 7, 3 \rightarrow 32, \text{stride } 2$	$S/2$	$2352 BS^2$
$5 \times 5, 32 \rightarrow 64$	$S/4$	$6400 BS^2$
$3 \times 3, 64 \rightarrow 128, \text{stride } 2$	$S/8$	$2304 BS^2$
$1 \times 1, 128 \rightarrow 256$	$S/8$	$1024 BS^2$
$3 \times 3, 256 \rightarrow 256, \text{stride } 2$	$S/16$	$4608 BS^2$
$1 \times 1, 256 \rightarrow 512$	$S/16$	$1024 BS^2$

$k \cdot k \cdot C_{in}$ - kernel смотрит на эту область $\Rightarrow$ умножений
 $B \cdot C_{out} \cdot S \cdot S$ - output, так как на один output надо
 $k^2 \cdot C_{in} \rightarrow$ то где все output - $k^2 \cdot C_{in} \cdot B \cdot C_{out} \cdot S^2$ умножений
 сложений = $(k^2 \cdot C_{in} - 1) \Rightarrow$ Итоговый FLOPS $\Rightarrow$
 $\Rightarrow (k^2 \cdot C_{in} + k^2 \cdot C_{in} - 1) \cdot B \cdot C_{out} \cdot S^2$ так IMAC = 2 FLOPS $\Rightarrow$
 $\Rightarrow 2 k^2 C_{in} \cdot B \cdot C_{out} \cdot S^2$

Relu и MaxPool не включают, так Max операцию. Можно преобразить, т.к $B \cdot S \cdot S^2$ где Relu = $B \cdot 32 \cdot \frac{S}{2} =$
 а где всех Relu = $21 BS^2$, ~~иногда~~
 как не операции $\{*, +\}$ не учитываются

Gap - $512 \cdot B \cdot \frac{S}{16} = 313344 B$
 linear = $2 \cdot B \cdot (N_{in} \cdot N_{out}) = 2 \cdot B \cdot (512 \cdot 256) + 2 \cdot B \cdot (256 \cdot 100) = 256 =$
 $= 313344 B + bias = 313344 B + 256 + 100 = 313700 B$

Итоговый FLOPS = $B \cdot (177145^2 + 313700)$
 Memory
 $N_{conv} = C_{in} \cdot C_{out} \cdot k^2$
 $N_{linear} = N_{in} \cdot N_{out} + N_{out} (bias)$
 $N = 1040324$, так как FP32 $W = 4 N = 4161296$ bytes

Измеряем max_memory_allocated(). Самый ПИК при MaxPool, так вхог после свертки + выделение под выход + исходное изображение (т.к measure.py оно хранится в кэше и используется где повторного запуска)

Input	$B \times 3 \times S \times S$	$3 BS^2$
Conv1	$B \times 32 \times \frac{S}{2} \times \frac{S}{2}$	$8 BS^2$
Relu		
Выход MaxPool	$B \times 32 \times \frac{S}{4} \times \frac{S}{4}$	$2 BS^2$
		$13 BS^2$

+ В реализации Pytorch хранятся индексы MaxPool 1 элемент $\rightarrow$ 1 индекс в int64 $\Rightarrow 8 (int64) \text{ bytes} = 2 BS^2$

Итоговая память = $4 \cdot 13 BS^2 + 2 \cdot 8 BS^2 + 4161296 + W =$
 $= 68 BS^2 + 4161296 \text{ bytes}$

Bytes moved, Пусть B_M - суммарный объем read and write данных за проход.
 $B_M = 4 \cdot N_{in} + 4 \cdot N_{out}$, где Relu аналогично
 Т.к надо считать еще $W \Rightarrow$
 $B_M = 380 BS^2 + 8592 B + 4161296 \text{ bytes}$ с учетом, что считается один раз где все батчи

conv	input	output	B_M , byte
conv1	$3 S^2$	$8 S^2$	$48 S^2$
Relu1	$8 S^2$	$8 S^2$	$64 S^2$
Conv2 + Relu	$2 S^2$	$4 S^2$	$56 S^2$
Conv3 + Relu	$4 S^2$	$2 S^2$	$40 S^2$
Conv4 + Relu	$2 S^2$	$1 S^2$	$56 S^2$
Conv5 + Relu	$4 S^2$	$1 S^2$	$28 S^2$
Conv6 + Relu	$1 S^2$	$2 S^2$	28
Global AvgPool	$2 S^2$	512	$8 S^2 + 2048$
lin1 + Relu	512	256	5120

- Latency - замерял как медианное одного forward в `eval()` + `inference_model()`
 Wall-clock, предполагаю t_0 - постоянные затраты на запуск и `const`
 эффективные скорости P, BW . при F -операции и P производительности
 один compute $T_{comp} = \frac{F}{P}$, P - ~~теоретическая~~ TFLOPS 10^{12} FLOPS, BW - эффективная пропускная способность
 $T_{memory} = \frac{D}{BW}$ в (GB/s - 10^9 байт/с)
 $T(s, B, \Theta) = t_0 + \max \left(\frac{B(17714s^2 + 313700)}{P \cdot 10^{12}}, \frac{4161296 + B(3805^2 + 8592)}{BW \cdot 10^9} \right)$
 $\Theta(t_0, P, BW)$
 P - суммарная пропускная способность (BW - в прошлом пункте)

- Энергия E_{NMA} до и после из N подходов. $E_{mean} = \frac{E_{after} - E_{before}}{1000}$
 предполагаю `const` (E_0 и $E_F + E_d$) $\Rightarrow E(s, B, \Theta) = E_0 + e_F \frac{B(17714s^2 + 313700)}{10^{12}} + e_d \frac{4161296 + B(3805^2 + 8592)}{10^9}$
 Все параметры Θ подбираются путем калибровки. Используется по `MASE.calibrate_grid`
 исключается из замеров